Presentación

- Físico. MBA y Máster Bl y BigData EOI (2012/2013)
- M&A. CEO empresa náutica I+D+I
- Consultor freelance
- Kaggle Máster
- Socio Asociación de Usuarios de R de España
- santiago_mota@yahoo.es
- http://es.linkedin.com/in/santiagomota



Capítulo 1

Kaggle

Kaggle

- Kaggle
- Marchamo "de facto" para data science (primeros = TRABAJO)
- Mas de 100.000 usuarios activos en todo el mundo (creciendo)
- Zona de test para los algoritmos mas avanzados (xgboost)
- What has Kaggle learned from 2M ML models?
- Lessons Learned from Running Hundreds of Kaggle Competitions



Netflix

- Mejorar el algoritmo de recomendación de las películas.
- Se desarrolló en distintas fases y se obligaba a publicar al final de cada fase.
- Colaboración en los foros.
- Ensamblado de soluciones.
- 1111111111 -> 1111111000 y 0001111111
- No se llegó a implementar.
- http://techblog.netflix.com/2012/04/netflix-recommendations-beyond-5-stars.html
- http://www.research.att.com/articles/featured_stories/2010_01/2010_02_netflix_article.html

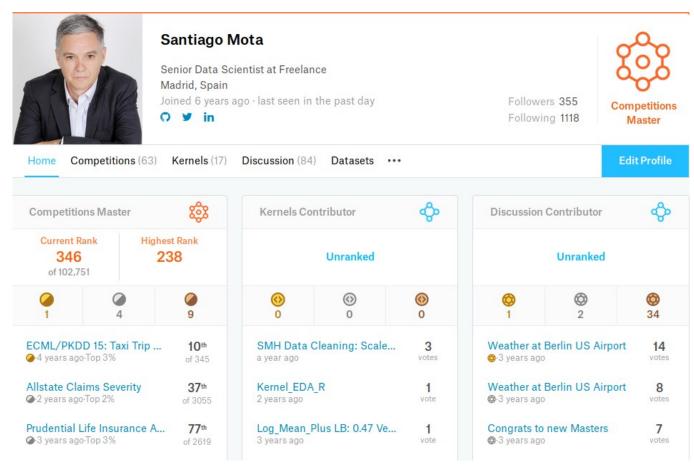


Kaggle

- Por qué puede ser interesante para vosotros? Conocimientos, puestos de trabajo, metodologías, algoritmos y contactos.
- ¿Qué aporta en referencia con el Open Data? Datos, código, traspaso de conocimientos, open data.
- Eligir el nombre con cuidado.
- Apuntarse a los foros.



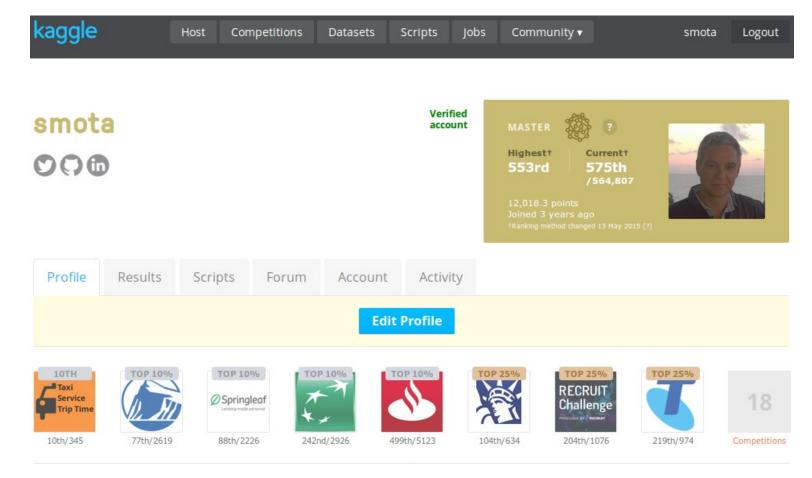
Perfil





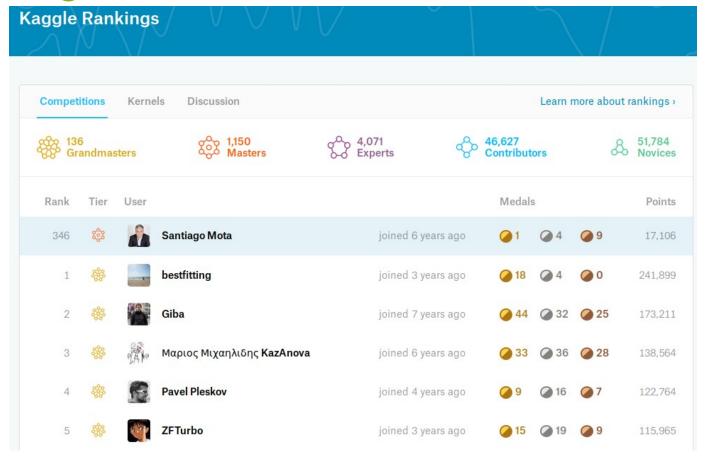


Perfil hace unos años





Rankings





Ranking, points, tiers

- Cinco niveles: Novice (44.000), Contributor (44.000), Expert (3.800), Master (1.000) y Grandmaster (125).
- También para kernels y foro.
- Los puntos "decaen".
- Son menos si se forma parte de un equipo.
- Medallas.

	0-99 Teams	100-249 Teams	250-999 Teams	1000+ Teams
Bronze	Top 40%	Top 40%	Top 100	Top 10%
Silver	Top 20%	Top 20%	Top 50	Top 5%
Gold	Top 10%	Top 10	Top 10 + 0.2%*	Top 10 + 0.2%*



Puntos

Points

Kaggle users are allocated points for their performance in competitions. The overall user rankings are shown at https://www.kaggle.com/users. These are recalculated at the end of every competition, once results have been finalized.

More points are earned for better results, with the maximum achievable points based on the number of total participants in the competitions, and a multiplier on the competition known as the "User Rank Multiplier". For certain competitions (e.g. Getting Started, or competitions with a public ground truth) the user rank multiplier of a competition is set to zero, meaning the competition will have no impact on users' points.

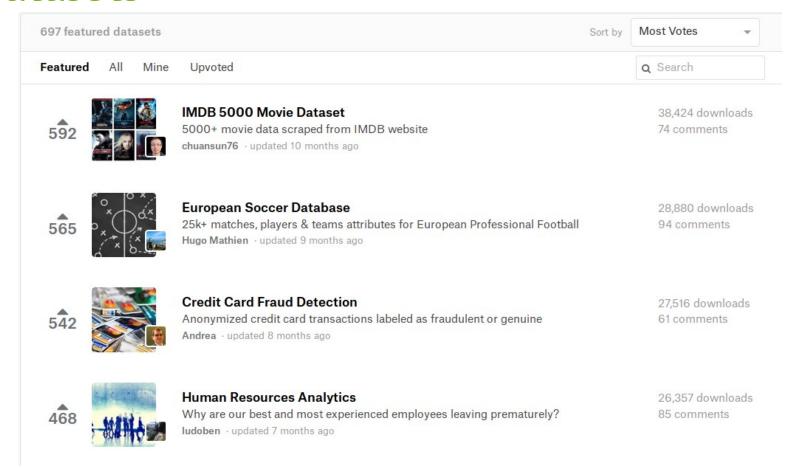
The current formula for each competition divides the points among the team members according to the square root, decays the points for lower finishes, adjusts for the number of teams that entered the competition, and decays the points as time elapses from the competition end. For each competition, the formula is:

$$\left[rac{100000}{\sqrt{N_{\mathrm{teammates}}}}
ight]\left[\mathrm{Rank}^{-0.75}
ight]\left[\log_{10}\left(1+\log_{10}\left(N_{\mathrm{teams}}
ight)
ight)
ight]\left[e^{-t/500}
ight]$$

Points are always calculated with time decay fixed at the time of the most recent competition deadline. Between competition deadlines points do not decay and ranks will not change.



Datasets

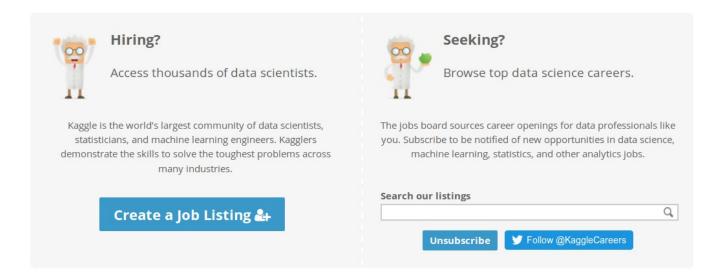


https://www.kaggle.com/datasets



Puestos de trabajo

Data Science Jobs Board



Featured Posts



★ Data Scientist Machine Learning

Booking.com · Tel Aviv posted yesterday

229 views



https://www.kaggle.com/jobs

Wiki

Learning Data Science

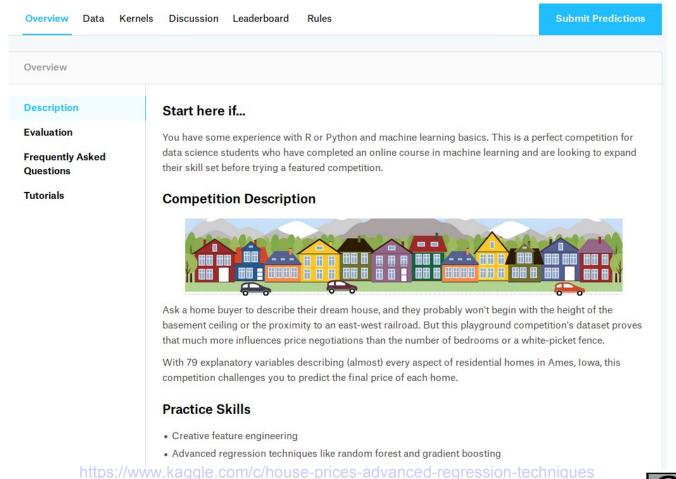
- What is Data Science?
- Data Science Tutorials
- Software for Data Scientists
- Statistical and Machine Learning Algorithms
- External Data Science Books, Courses and References
- Data Science Blogs
- Data Sources

Information for Participants

- Kaggle Member FAQ
- Entering your First Submission
- Forming a Team
- Leaderboard
- Competition Scoring Metrics
- Strategy and Tactics
- Solutions to past competitions
- User Ranking and Tiers
- Winning Model Documentation Template
- Kaggle Connect Program
- Open Competition Data Sets

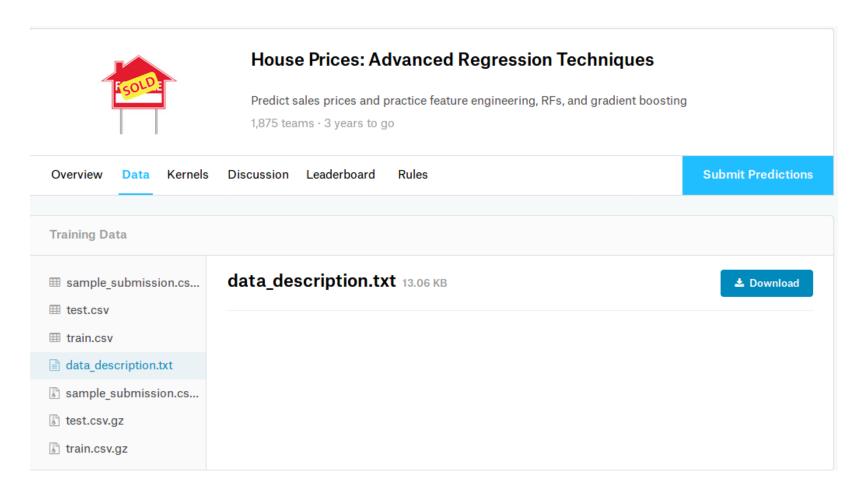


Overview

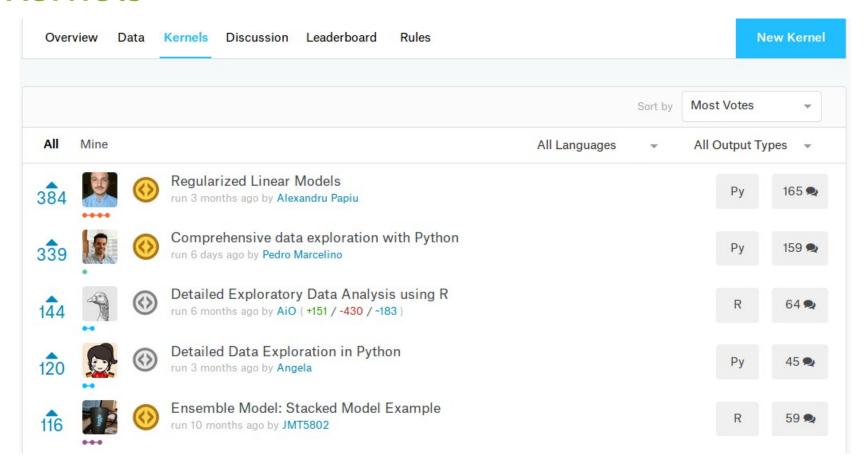




Datos



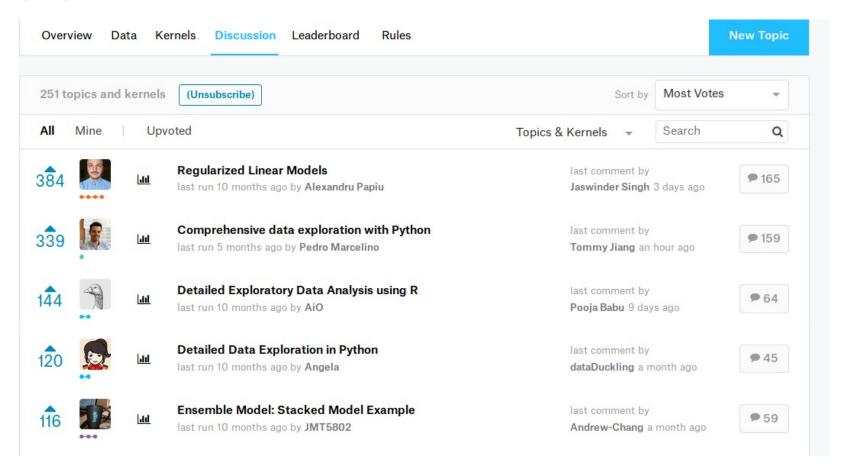
Kernels





Kaggle

Foro





Rules

Overview Data Kernels Discussion Leaderboard Rules Submit Predictions

One account per participant

You cannot sign up to Kaggle from multiple accounts and therefore you cannot submit from multiple accounts.

No private sharing outside teams

Privately sharing code or data outside of teams is not permitted. It's okay to share code if made available to all participants on the forums.

Team Mergers

Team mergers are allowed and can be performed by the team leader. In order to merge, the combined team must have a total submission count less than or equal to the maximum allowed as of the merge date. The maximum allowed is the number of submissions per day multiplied by the number of days the competition has been running.

Team Limits

There is no maximum team size.

Submission Limits

You may submit a maximum of 5 entries per day.

You may select up to 2 final submissions for judging.

Competition Timeline

Start Date: 8/30/2016 1:08 AM UTC

Merger Deadline: None
Entry Deadline: None

End Date: 3/1/2017 11:59 PM UTC

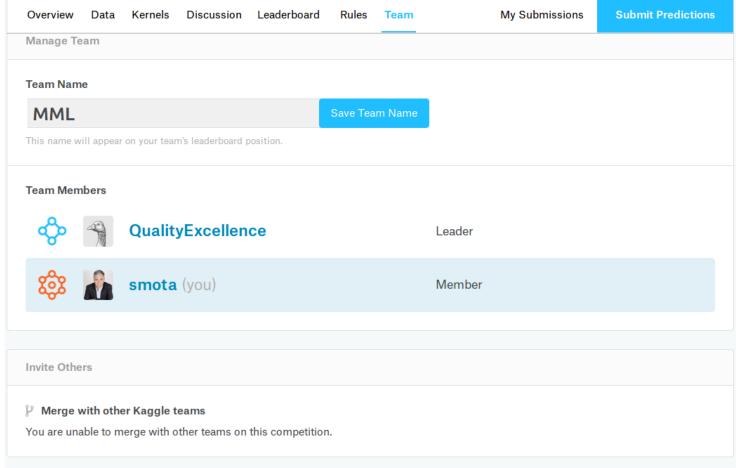
- · Due to the public nature of the data, this competition does not count towards Kaggle ranking points.
- We ask that you respect the spirit of the competition and do not cheat. Hand-labeling is forbidden.

https://www.kaggle.com/c/house-prices-advanced-regression-techniques/rules



Kaggle

Team



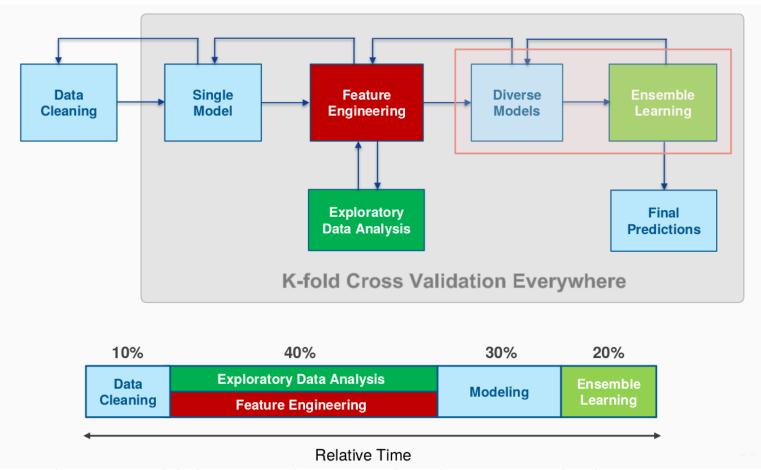


Al empezar el concurso

- Tipo de concurso. ¿Alguno anterior?
- Cantidad de datos.
- Métrica de evaluación (library(Metrics)) y (General).
- Fechas límite.
- Partición public/private leaderboard.
- Subscribirse al foro.
- Buscar en Github.
- Leer las condiciones.
- Reproducción de la solución final.



Proceso de trabajo



https://www.slideshare.net/markpeng/general-tips-for-participating-kaggle-competition



Estrategias

- Formación de equipos (límites).
- Kernels.
- Número de submissions al día.
- ¿Sobre cuantos modelos se hará la evaluación final?
- Elección de los modelos para el private leaderboard.
- Gestión de tiempos (dedicación).
- ¿Me fio del public leaderboard (overfitting)?
- Foro durante el concurso y al finalizar (huevos de pascua).



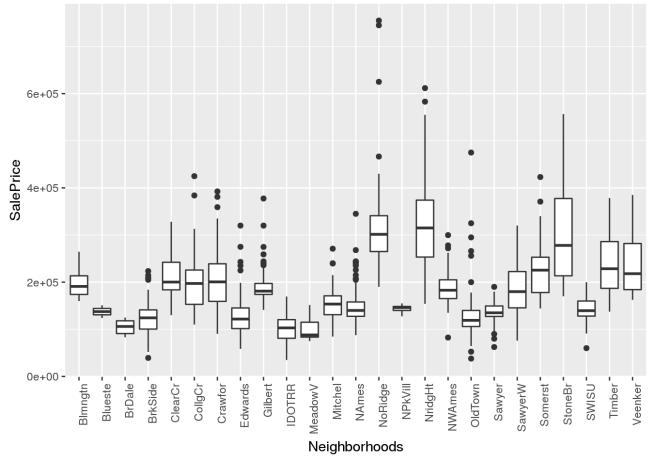
Varios

- Data leakege (link).
- Cuentas anónimas / imagen.
- Preguntar en el foro (puntos).
- Confirmación por SMS.
- Seed (xgboost).
- Titanic.
- 50% python, 40% R, 10% otros.
- Trampas.
- Metodología de trabajo (inversion).



Concurso precios de alquileres

Página del concurso. Tutoriales. Kernels y Foro



¿Cuanto cuesta?

- En Kaggle el coste (premios incluidos) es de unos 100.000\$.
- Se incluye la preparación, seguimiento y análisis.
- Opciones gratuitas:
- Como profesor, en ese caso se limita y los alumnos y no se da asistencia (Kaggle Inclass).
- Con un proyecto que les parezca interesante.



Otras plataformas

- CrowdAnalytics (link).
- DrivenData (link).
- Devpost (link).
- Innocentive (link).
- TunedIT (link).
- Enlaces a competiciones en Kdnuggets (link).



Concursos presenciales

- Fin de semana vs extensos en el tiempo.
- Dotación económica.
- En equipo (casi siempre).
- Uso de otras "soft-skills".
- Mas valor de la idea/presentación vs. datos/algoritmo.
- Limitaciones: Tiempo, datos, presentación.



GRACIAS

Datos de contacto:

Santiago Mota Herce

Teléfono: 670702852

Twitter: @mota_santiago

E-mail: santiago_mota@yahoo.es

LinkedIn: https://es.linkedin.com/in/santiagomota



Capítulo 2

Donde continuar

Bibliografía

- Introducción a R (castellano).
- R para principiantes (castellano).
- An introduction to R (inglés).
- R programming for data science (inglés).
- R for data science (inglés / pago).
- R For Dummies (inglés / pago).



Kaggle

Webs

- R blogglers
- KD nuggets
- Data Science Central
- GitHub
- Kaggle
- Medium



Chuletas

- Sobre R en general: <u>Una</u>, dos, tres y cuatro
- Varias de Rstudio. Entre ellas Markdown, Rstudio o Shiny
- ggplot2
- Expresiones regulares
- dplyr
- data.table
- En Rstudio (\Help\Cheatsheets)



MOOC

- Introducción a R (Datacamp).
- Introduction to R (MIcrosoft).
- R programming Johns Hopkins. Peng y Leek (data science).
- Statistical Learning. Stanford.



Otros

- Asociación de usuarios de R de España
- Meetup Grupo de Usuarios de R de Madrid
- Jornadas nacionales de usuarios de R
- Stackoverflow (poner [r] en la búsqueda)
- Glosario de Machine Learning de Google
- Essentials of Machine Learning Algorithms
- Pautas de Google en el estilo de programación
- BI and Big Data Open Sourced

